FarmaPredict · Bitácora 3–5/11: hallazgos, fallos y correcciones

Nov 5, 2026 · @Alejandro Ronda Navazo

Resumen

Entre el 03/11 y el 05/11 se resolvió el principal riesgo del proyecto, que la Fase 1 calificaba de impacto alto: "CIMA no ofrece histórico suficiente". El listado de problemas de suministro solo devuelve los activos, pero se encontró un endpoint por CN que conserva el último episodio resuelto. Con él se hizo un backfill de los 42.083 CN del catálogo, y se montó un snapshot diario automático para tener histórico completo desde el 04/11.

Estado al cierre del 05/11:

- **Ingesta:** cliente CIMA con reintentos, snapshot diario de `psuministro` en GitHub Actions (rama `snapshots`) y backfill en curso.
- **Backend:** capa de datos (`datos.py`) y recomendador de sustitutos (`servicios.py`) probados; código de la API FastAPI redactado, pendiente de probar.
- **Equipo:** documento de traspaso con las tareas de limpieza y modelo, y tablero con 26 tarjetas hasta la entrega de NF3 (12/11).

Hallazgos sobre los datos de CIMA

Cada hallazgo se obtuvo con una prueba concreta contra la API y condicionó una decisión de diseño.

Hallazgo	Evidencia	Decisión que provocó
`/psuministro` solo devuelve incidencias **activas**	920 registros el 04/11, todos con `activo: true`, 0 cerrados, 1 por CN	Snapshots diarios para construir histórico propio
La distribución por año de inicio es **sesgo de supervivencia**	3 incidencias de 2016 frente a 691 de 2026: solo sobreviven las crónicas	No usarla como "evolución de los desabastecimientos"

Hallazgo	Evidencia	Decisión que provocó
`ffin` en incidencias activas es una **previsión** que cambia	5 CN la cambiaron en un día; Visipaque tenía `ffin` en 11/2027 y se resolvió el 05/11	El fin real sale de la desaparición entre snapshots; `ffin` se renombra a `fecha_fin_prevista`
`/psuministro/v2/cn/{cn}` conserva el **último episodio resuelto** con fechas reales	Los 8 CN que desaparecieron entre el 04/11 y el 05/11 devolvieron `activo: false` y `ffin` del 05/11	Backfill de los 42.083 CN (una sola vez) combinado con los snapshots
Ese endpoint solo da **un episodio por CN**, no una lista	Respuesta: un objeto, no un array	Sesgo documentado: en cortes antiguos faltan positivos
Un CN sin problemas devuelve 200 con `observ: "Sin problemas de suministro reportados"`, y el `cn` viene como **int**	Prueba con 5 CN del catálogo	El backfill usa como clave el CN consultado (texto)
Las fechas son epoch en ms, a medianoche de Madrid guardada en UTC	`1793746800000` = 04/11 en Madrid, 03/11 en UTC	Conversión con `tz_convert("Europe/Madrid")` antes de sacar el día
`tipoProblemaSuministro`: códigos 1–9 documentados en un PDF de 2019; los 10–12 no	76 % de las activas son tipo 5 o 6 (existe alternativa)	Tabla en el código con su fuente; decisión abierta sobre qué tipos cuentan como positivo
`/presentaciones`: 42.083 CN y 7.054 DCP distintos	Snapshot del 05/11	El DCP es la clave de los sustitutos equivalentes
CIMA responde desde los runners de GitHub	Ejecución manual del 05/11: 912 registros	La ingesta diaria puede ir en GitHub Actions
Ritmo del backfill: 4,2 CN/s; 4,5 % de los CN con episodio	Prueba con 200 CN	Unas 2 h 45 min para todo el catálogo, lanzado en local

Fuente de la tabla de tipos: CIMA REST API – Problemas de suministro (AEMPS, 2019).

Fallos y correcciones

Ordenados del más reciente al más antiguo. La mayoría son fallos de integración y de flujo de Git, no de lógica; las lecciones de la última columna son las que conviene llevar a la memoria.

Fecha	Fallo	Causa	Corrección	Lección
05/11	El recomendador por "mismo principio activo" ofrecía enemas, comprimidos y cremas como alternativa a un inhalador	Criterio demasiado amplio	Dos niveles: equivalentes (mismo DCP) y alternativas a valorar (mismo principio activo **y misma vía**, cruzando con `/medicamentos`)	El criterio de equivalencia es una decisión sanitaria; se toma de la AEMPS (tipo 5: "mismo principio activo y vía")
05/11	Becloforte con problema de suministro: 0 sustitutos	El DCP incluye dosis y forma; las alternativas reales tienen otra dosis	Nivel de "alternativas a valorar" (3 beclometasonas inhaladas)	Probar con un caso real con problema, no solo con casos sin problema
05/11	Al buscar "ibuprofeno" salía primero "Couldina con ibuprofeno"	Orden solo alfabético	Prioridad a los nombres que empiezan por la consulta	
05/11	`pip install` bloqueado ("Control de aplicaciones")	Windows bloquea `pip.exe` del entorno virtual, pero no Python	`python -m pip install ...`	Documentarlo en el README: le puede pasar al corrector
05/11	Riesgo de fallo de `zoneinfo` en Windows	Windows no trae la base de datos de zonas horarias	`tzdata` fijado en `requirements.txt`	
05/11	PR de activación del cron "no hecha"	Faltaba abrir la PR, la rama estaba bien	Abrir PR desde "Compare & pull request"	
05/11	Imports de `HTTPAdapter` y `Retry` duplicados en `api.py`	Se añadieron dos veces al copiar	Limpieza de imports antes de llevarlo a `main`	Revisar el diff antes de cada PR
04/11	El workflow fallaba en `setup-python`	La rama `api` no tenía `requirements.txt` y `cache: pip` lo necesita	`requirements.txt` con versiones fijadas	Fijar versiones: un proceso desatendido no puede romperse por una actualización
04/11	El cron se habría ejecutado en `main` sin el código	Los `schedule` siempre usan el código de la rama por defecto	`schedule` comentado hasta mergear el código; activado el 05/11	Separar "probar a mano en una rama" de "activar el cron"
04/11	La PR `ci/snapshot-workflow` mostraba todos los ficheros de `api`	La rama se creó desde `api` en lugar de desde `main`	Recreada con `git switch -C ... origin/main` y `push --force-with-lease`; antes se rescató a `api` el commit `a0c9143`, que solo existía en esa rama	Crear ramas siempre desde `origin/main`; comprobar con `git log origin/main..HEAD` antes del push

Fecha	Fallo	Causa	Corrección	Lección
04/11	El snapshot del 04/11 "desapareció" al crear la rama `snapshots`	Estaba commiteado en `api` (`data/` no está en `.gitignore`) y `switch --orphan` lo quitó del disco	Recuperado y movido a mano	`data/` debería estar en `.gitignore` (pendiente, decisión del equipo)
04/11	`copy` fallaba con la ruta `..\data\...`	Ruta relativa que salía del repo	Ruta desde la raíz del repo	
04/11	`NameError: endpoint` en `_get_json`	Errata en el parámetro (`endpont`)	Corregida	Un linter (Ruff o Pylance) detecta estos errores sin ejecutar
04/11	`NameError: HTTPAdapter` al importar `api.py`	Faltaban los imports	Añadidos; además, `_cerrar_sesion` renombrada a `_crear_sesion`	Los nombres deben decir lo que hace la función
04/11	`main.py` no arrancaba	`from turtle import pd`, añadido por el autoimport del IDE	`import pandas as pd`	Revisar los imports que añade el IDE
04/11	`time` y `guardar_modelos` solo existían por `from src.api.api import *`	Import con asterisco	Imports explícitos	
03/11	Ningún módulo de `src/api` podía importarse	`DataFrame` en una firma sin importar pandas (`NameError`)	`from pandas import DataFrame`	Ejecutar el código antes de subirlo
03/11	La capa raw de medicamentos no era raw	Se guardaba el volcado de Pydantic con `extra="ignore"`, que descarta campos	Para `psuministro`: JSON tal cual (`guardar_raw`); medicamentos, pendiente de decidir	Validar en raw → cleaned, nunca al descargar
03/11	Bug latente: `med.get("formaFarmaceuticaSimplificada" or {})`	El `or {}` estaba dentro del `get`	`(med.get(...) or {}).get("nombre")`	
03/11	`nregistro` con y sin ceros a la izquierda en distintos CSV	Un CSV antiguo los rellenaba	CN y `nregistro` siempre como texto, sin rellenar	Fijar el formato de las claves antes de cruzar tablas

Decisiones tomadas

Decisión	Motivo
Raw = JSON tal cual de la API, sin Pydantic (aplicado a `psuministro`)	Un dato descartado al descargar no se recupera; la validación va en raw → cleaned
Un snapshot por día, idempotente y con escritura atómica	Se puede relanzar sin duplicar ni dejar ficheros a medias
Snapshot diario en GitHub Actions, en una rama huérfana `snapshots`	No depende de que un PC esté encendido. Es el plan B (cron) que la Fase 1 ya contemplaba frente a Airflow

Decisión	Motivo
Dos ejecuciones al día (07:17 y 19:17, hora de Madrid)	GitHub puede retrasar o perder ejecuciones programadas
`FARMAPREDICT_RAW_DIR` configurable por variable de entorno	El workflow escribe en el checkout de `snapshots` sin copias ni enlaces
Backfill único el 05/11, reanudable (JSONL), más snapshots desde el 04/11	El backfill da el pasado (parcial) y los snapshots, el presente (completo)
Clave de una incidencia: `(cn, fecha_inicio)`	Un CN puede tener varios episodios a lo largo del tiempo
Sustitutos en dos niveles: mismo DCP, y mismo principio activo más misma vía	Utilidad sin presentar como equivalente lo que no lo es
Backend en `src/backend/`, separado de `src/api/` (cliente CIMA)	Evitar dos carpetas "api" con significados distintos
Capas `rutas` → `servicios` → `datos`	La lógica se testea sin servidor; cambiar de ficheros a PostgreSQL solo toca `datos.py`
Modelo de NF3: regresión logística comparada con una tasa ingenua; XGBoost en NF4	Es la *baseline* que define la Fase 1
PostgreSQL y Docker Compose aplazados a NF4	Prioridad: cerrar el flujo completo. Coste asumido: probable 0,5 en el criterio 3 de la rúbrica
`data/` sigue versionado de momento	Que todo el equipo tenga los datos; se pasará a `.gitignore` más adelante

Nuevo reparto (05/11): la limpieza de datos pasa a Francisco y el backend (API) a Mohamed, para descargar a Alejandro. Alejandro mantiene ingesta, backfill, recomendador y `datos.py`, que ya están hechos o en curso.

Limitaciones conocidas para la memoria

Pensadas para el apartado 9 del PDF ("Limitaciones actuales"), que puntúa la honestidad técnica.

- **Histórico parcial antes del 04/11:** el backfill solo trae el último episodio de cada CN, así que faltan los episodios anteriores de los medicamentos con problemas recurrentes.

- **El backfill es una foto del 05/11 que no se puede repetir:** la AEMPS sobrescribe el último episodio de cada CN.
- **Fin de incidencia con precisión de un día,** y menor si falla algún snapshot.
- **Códigos 10, 11 y 12 de `tipoProblemaSuministro` sin documentar;** se muestran como "Tipo sin documentar".
- **Sin DCP o sin vía conocida no se recomienda nada,** por precaución.
- **Los sustitutos son informativos:** la decisión es del farmacéutico, sobre todo en las "alternativas a valorar", que tienen otra dosis o forma.
- **El raw de `medicamentos` sigue pasando por Pydantic** al descargarse; pendiente de decidir.
- **`data/` está versionado en git,** en contra de lo que dice el README; pendiente de pasar a `.gitignore`.
- **Sin PostgreSQL ni Docker Compose en NF3:** los datos se sirven desde ficheros a través de `datos.py`.
- **La búsqueda recorre las 42.083 presentaciones en cada petición;** suficiente para NF3, mejorable con un índice.