

FarmaPredict: Predicción de desabastecimientos de medicamentos y recomendación de sustitutivos

Equipo (4 personas)	Repositorio y fecha límite
Alejandro Ronda (Data) · Francisco Antonio Tortosa (ML) · Alejandro Ronda (Platform) · Mohamed Ayman Oumghar Seghrouchni (BI)	https://github.com/arondax/farmapredict · Entrega: 22/09/2026

1. Elevator pitch

La información sobre problemas de suministro de medicamentos es pública pero está dispersa, y las farmacias suelen reaccionar cuando el problema ya ha llegado al mostrador. **FarmaPredict** es una plataforma de datos e IA para oficinas de farmacia y distribuidores sanitarios que recoge automáticamente las incidencias de suministro publicadas por la AEMPS (CIMA), estima la probabilidad de que un medicamento sufra desabastecimiento en los próximos 30 días y recomienda sustitutivos equivalentes (mismo principio activo, dosis y forma). Aporta anticipación en las compras y continuidad en los tratamientos, con una API y un dashboard listos para usar.

2. El tema y el problema

Qué pasa hoy. En España se registran de forma continua incidencias de suministro de medicamentos, incluidos de uso muy común (antibióticos pediátricos, antidiabéticos, antihistamínicos). La AEMPS las publica en CIMA, pero la información está fragmentada y es reactiva: informa de lo que ya ha ocurrido, no de lo que probablemente ocurrirá.

Qué duele. Las farmacias pierden ventas, sufren atascos en la atención y no pueden prever sus pedidos. Los pacientes ven interrumpido su tratamiento cuando no encuentran su fármaco ni una alternativa equivalente en el acto.

Por qué es importante. Anticipar el riesgo permite comprar con antelación y ofrecer una alternativa equivalente al momento, protegiendo la continuidad asistencial del paciente.

3. Objetivo principal

Construir una plataforma que permita estimar el riesgo de desabastecimiento de un medicamento en los próximos 30 días y recomendar sustitutivos equivalentes, para que farmacias y distribuidores anticipen sus pedidos y eviten interrumpir tratamientos.

Criterios de éxito: (1) el clasificador supera en PR-AUC a una línea base ingenua (tasa histórica de incidencias por código ATC); (2) el recomendador propone al menos un sustituto para la mayoría de los medicamentos con problema de suministro; (3) todo el sistema se levanta con un único docker compose up. Los umbrales numéricos se fijarán tras medir la línea base (semana 2).

4. Alcance inicial (IN / OUT)

DENTRO (MVP)	DENTRO CONDICIONADO (solo con el MVP cerrado)	FUERA
- Ingesta programada (Airflow) desde la API REST de AEMPS CIMA a PostgreSQL, con snapshots diarios para construir histórico propio. - Clasificador XGBoost de riesgo de desabastecimiento a 30 días, comparado con una línea base. - Recomendador de sustitutivos por reglas (principio activo, dosis y forma). - API REST en FastAPI (riesgo y sustitutivos). - Dashboard en Streamlit: alertas y comparador de sustitutivos. - Entorno reproducible con Docker Compose y tests básicos (PyTest).	- Previsión de demanda estacional por ATC (Prophet) con datos del Ministerio de Sanidad. - Ordenación de sustitutivos por similitud de fichas técnicas (embeddings + Qdrant). - PySpark, solo si el volumen de datos lo justifica. - Simulador de pedidos con datos sintéticos.	- Integración con robots de almacenamiento, ERPs o receta electrónica. - Aplicaciones móviles nativas. - Diagnóstico médico o prescripción clínica. - Datos reales de farmacias, autenticación y multiusuario. - Despliegue en la nube. - Reentrenamiento automático y monitorización de modelos.

Regla de alcance: nada de la columna condicionada entra en un sprint hasta que el MVP funcione de extremo a extremo. Los sustitutivos que recomienda el sistema son informativos: la decisión final es siempre del farmacéutico.

5. Usuarios y partes interesadas

- Usan:** farmacéuticos titulares y gestores de compras de oficinas de farmacia.
- Deciden:** cooperativas de distribución farmacéutica y cadenas de farmacias (quienes adoptarían y pagarían la herramienta).

- **Se benefician:** los pacientes (continuidad del tratamiento) y las farmacias (menos ventas perdidas y mejor previsión de pedidos).
- **Pueden verse afectados:** pacientes, si se siguiera un sustitutivo inadecuado (por eso el sistema es informativo), y laboratorios cuyos productos aparezcan con riesgo alto.

6. Propuesta de solución (alto nivel)

Pieza	Rol dentro del sistema	Tecnología provisional
Ingesta y ETL	Descarga programada de CIMA, limpieza y carga; guarda snapshots diarios para construir el histórico.	Apache Airflow, Python
Almacenamiento	Catálogo de medicamentos, histórico de suministro y variables para el modelo.	PostgreSQL
Modelo de riesgo	Clasificador binario a 30 días y modelos de referencia para compararlo.	XGBoost, regresión logística
Recomendador	Sustitutivos equivalentes por reglas sobre principio activo, dosis y forma.	SQL / Python (ampliación: embeddings + Qdrant)
API	Expone riesgo y sustitutivos al dashboard y a terceros.	FastAPI
Dashboard	Semáforo de riesgo por medicamento y comparador de sustitutivos.	Streamlit, Plotly
Entorno	Despliegue reproducible de todos los servicios.	Docker Compose

7. Datos (estimación inicial)

- **API REST de AEMPS CIMA (pública).** Más de 15.000 medicamentos con códigos ATC, fichas técnicas y problemas de suministro. Tipo: tabular (JSON), texto (fichas técnicas) y series temporales (histórico de incidencias).
- **Facturación de recetas del SNS, Ministerio de Sanidad (pública, agregada).** Proxy de demanda real. Granularidad por verificar en la semana 1 (ATC, mes, provincia).
- **Generador sintético (Faker + NumPy).** Ventas por oficina de farmacia. Solo valida el pipeline, el dashboard y el volumen; no se usará para evaluar la capacidad predictiva, porque replicaría la estacionalidad con la que se genera.

Etiqueta. Se considerará desabastecimiento cuando exista un problema de suministro activo para el medicamento en los 30 días posteriores a la fecha de referencia (definición sujeta a lo que devuelva CIMA).

Riesgos de acceso y licencias. Revisaremos las condiciones de reutilización de CIMA y del Ministerio y los límites de uso de la API antes de automatizar la ingesta. No se tratan datos personales ni de salud individuales (cumplimiento del RGPD por diseño) y los datasets no se suben al repositorio.

Alternativas. Si al final de la semana 1 no hay datos del Ministerio con granularidad suficiente, la demanda pasará a apoyarse en el generador sintético y se declarará como demostración del pipeline. Si CIMA no estuviera disponible, se trabajará con snapshots y con una caché local en PostgreSQL.

8. Viabilidad técnica (análisis mínimo)

Partes fáciles. Ingesta desde la API, modelado relacional del catálogo, dashboard y recomendador basado en reglas: son datos tabulares y de texto de tamaño moderado, y no hacen falta redes neuronales.

Partes difíciles.

- Construir la etiqueta y un histórico usable a partir de lo que publica CIMA.
- Desbalanceo de clases: los desabastecimientos son minoría.
- No hay datos reales de demanda por farmacia ni de las causas de la rotura (las farmacéuticas no las publican).
- Evaluar los sustitutivos sin verdad de referencia: se contrastarán con las equivalencias oficiales por principio activo y forma.
- Desplegar varios servicios en Docker Compose en cuatro equipos distintos.

Tecnología y por qué. XGBoost por tratarse de datos tabulares de tamaño moderado, con pesos de clase para el desbalanceo; se compara con regresión logística y con la línea base, y se mide con PR-AUC. Airflow, PostgreSQL, FastAPI, Streamlit y Docker Compose por reproducibilidad y rapidez de desarrollo. Spark, Qdrant y Prophet quedan como ampliación: 15.000 medicamentos no justifican Spark, y las equivalencias exactas se resuelven en SQL.

Incertidumbres. (a) Si el endpoint de suministro de CIMA devuelve histórico con fechas de inicio y fin o solo los problemas activos. (b) La granularidad real de los datos del Ministerio. (c) Los límites de uso de la API. (d) Si los desabastecimientos son predecibles con las variables disponibles: el modelo podría no superar la línea base; en ese caso se documentará como resultado y el valor recaerá en el recomendador y el dashboard.

9. Riesgos principales y Plan B

Riesgo	Impacto	Qué haremos si ocurre
CIMA no ofrece histórico suficiente de problemas de suministro	Alto	Acumular snapshots diarios desde la semana 1 para construir el histórico propio; mientras tanto, entrenar con el histórico disponible y reducir la salida a niveles Bajo / Medio / Alto.
Caída, cambios o límites de uso de la API de CIMA	Alto	Caché local en PostgreSQL y descarga de snapshots como fuente de respaldo.
Datos de demanda sin granularidad suficiente	Medio	La demanda pasa a la columna condicionada y se usa el generador sintético, declarado solo como demostración del pipeline.
El modelo no supera la línea base o el desbalanceo lo distorsiona	Alto	Pesos de clase y PR-AUC como métrica; revisar variables y horizonte; si no mejora, documentarlo como resultado y centrar el valor en recomendador y dashboard.
Alcance excesivo y falta de tiempo	Alto	MVP separado de las ampliaciones; revisión semanal contra esta matriz IN/OUT; si hay retraso, se recortan primero las ampliaciones.
Complejidad del entorno (Airflow, Docker en 4 equipos)	Medio	Servicios mínimos en el MVP; Spark y Qdrant solo como ampliación; si Airflow da problemas, script programado con cron.
Restricciones de licencia o reutilización de las fuentes	Medio	Revisarlas en la semana 1; si hubiera límites, trabajar con datos descargados sin redistribuirlos y citar la fuente.
Uso indebido de los sustitutivos recomendados	Medio	Salida informativa con aviso visible; la decisión es del farmacéutico; queda fuera cualquier prescripción.

10. Reparto de tareas por roles

Rol	Responsable	Apoyo en	Tareas principales
Data	Alejandro Ronda	ML	Ingesta desde CIMA, PostgreSQL, DAGs de Airflow, análisis exploratorio y recomendador de sustitutivos por reglas.
ML	Francisco Antonio Tortosa	Data	Variables, etiqueta, XGBoost y modelos de referencia, evaluación (y Prophet / embeddings si hay ampliación).
Platform	Alejandro Ronda	BI	API FastAPI, Docker Compose, tests con PyTest, gestión de PR y servicios de inferencia.
BI	Mohamed Ayman Oumghar Seghrouchni	Platform	Dashboard en Streamlit, KPIs, comparador de sustitutivos, README y documentación del repositorio.

Cada persona lidera un rol y da apoyo a otro; las decisiones de diseño se documentan en issues o PR.

11. Próximos pasos inmediatos (7 días)

Nº	Acción	Responsable	Fecha
1	Crear el repositorio farmapredict en GitHub, dar acceso al equipo y subir estructura de carpetas y .gitignore.	Alejandro	20/09 (antes de entregar)
2	Redactar el README inicial y crear el tablero de issues del Sprint 1 con responsable en cada una.	Francisco	21/09
3	Probar la API de CIMA y comprobar si el endpoint de suministro devuelve histórico con fechas de inicio y fin.	Data	
4	Descargar un dataset preliminar de CIMA en data/ (ignorado por Git) y hacer un primer análisis exploratorio.	Data	
5	Localizar el dataset de facturación del Ministerio, verificar su granularidad y revisar las condiciones de reutilización de las fuentes.	ML	
6	Definir la etiqueta de desabastecimiento y calcular la línea base (tasa histórica por ATC).	ML	
7	Levantar un docker-compose mínimo con PostgreSQL y una API FastAPI con endpoint de salud.	Platform	
8	Esquema del dashboard (wireframe) y KPIs iniciales.	BI	

12. Acuerdo de trabajo (resumen)

- **Canal principal:** Discord (WhatsApp solo para avisos urgentes).
- **Reuniones:** Semanal, según horario. El resto del trabajo es asíncrono, con respuesta en un máximo de 24 h; las ausencias se avisan con antelación en el canal.
- **Reglas básicas:** no se sube nada a main sin PR aprobada por al menos otra persona; todo trabajo tiene issue asignada; se documentan las decisiones; se respeta el reparto, pero se ayuda cuando alguien se bloquea.

13. Repositorio inicial

Repositorio Git accesible para todo el equipo con README.md (nombre, objetivo, miembros y organización del repo) y la estructura base: docs/ (incluye este PDF) · src/ · data/ (solo .gitkeep) · environment/ · README.md · .gitignore.